MACHINE LEARNING

ENGENHARIA DE SOFTWARE

CLASSIFICAÇÃO DE COMPRAS PÚBLICAS COM PREÇO ATÍPICO E PREVISÃO DO PREÇO ESPERADO USANDO MACHINE LEARNING CLÁSSICO

Professor: Rodrigo Ramos Silva

Alunos: Mateo Ramiro Zapelini, Miguel Torres

1.1Contextualização do problema real

O projeto trata de compras públicas, uma área da administração pública ligada ao controle interno e à auditoria.
Escolhemos um item que praticamente todo órgão compra: papel para impressão. Por ser um produto simples e padronizado, fica mais fácil perceber quando um preço sai do padrão.
Hoje o controle do preço é feito de três formas, e todas têm problema:

- Pesquisa de preços manual: antes de comprar, o servidor junta pelo menos três preços e calcula a média, a mediana ou o menor valor, descartando os valores "inexequíveis, inconsistentes e excessivamente elevados" (BRASIL, 2021b, art. 6º). A norma não diz o que é "excessivamente elevado", então a decisão depende de quem faz a pesquisa.
- Consulta a painéis: ferramentas como o Painel de Preços mostram quanto outros órgãos pagaram, mas só respondem a quem pergunta. Não avisam sozinhas que uma compra saiu fora do padrão.
- Auditoria por amostra: os órgãos de controle não conseguem olhar todas as compras. Revisam uma amostra ou as compras mais caras, e o que está fora disso passa sem ser visto.

DATASET ESCOLHIDO

Dataset escolhido. Usamos a API de Dados Abertos do Compras.gov.br (COMPRAS.GOV.BR, 2026a), módulo de Pesquisa de Preço, rota 1_consultarMaterial, filtrando o PDM 19746 (papel para impressão formatado) no ano de 2025. Como a coleta foi feita página por página, usamos as 18 primeiras páginas de 75 registros que a API devolve, ou seja, as 1.350 compras mais recentes de 2025, de 8 de agosto a 31 de dezembro. As características de cada papel (tipo, tamanho, gramatura e cor) vieram do catálogo de materiais, rota 4_consultarItemMaterial. O conjunto, que chamamos de compras_papel_2025 (arquivo compras_papel_2025.csv), pode ser obtido pela API em https://dadosabertos.compras.gov.br/swagger-ui/index.html, e os dados abertos de compras do governo federal estão descritos em COMPRAS.GOV.BR (2026b). Acesso em 25 de setembro de 2026.

1.2 Definição do problema de Machine Learning

O projeto tem duas etapas

1. Classificação binária: prever se uma compra tem perfil de risco de sair com preço atípico (sim ou não), usando só o que se sabe da compra antes de olhar o preço
Na classificação, é a coluna compra_atipica, que construímos. Ela vale 1 quando o preço por quilo da compra fica acima de Q3 + 1,5 × IQR (limite de preço normal do grupo; acima dele, a compra é atípica) do seu tipo de papel, regra sugerida no guia do projeto, e 0 caso contrário

2. Regressão: estimar o preço esperado da compra, em reais por quilo de papel, a partir das características do item e da compra.
Na regressão, o alvo é o preco_kg, o preço pago por quilo de papel.

1.3 Justificativa e relevância

Impacto. O modelo transforma milhares de compras soltas numa fila ordenada pelo dinheiro que pode ter sido pago a mais. Com isso, a equipe de controle interno, que não consegue olhar tudo, olha primeiro o que mais importa. Ganha-se em três frentes: a revisão foca onde há dinheiro em jogo, os erros de cadastro são corrigidos antes de contaminar outras pesquisas de preço, e o gestor tem uma referência objetiva do preço esperado

Relevância do Machine Learning. Por que não resolver isso com uma regra simples, do tipo "revisar tudo que custou mais que o dobro da mediana"?
O preço depende de muitas coisas ao mesmo tempo: tipo de papel, tamanho, gramatura, cor, embalagem, quantidade, região e forma de compra. Uma regra fixa precisaria de uma mediana para cada combinação, e muitas combinações têm poucas compras.

1.3.1 Objetivo geral

Desenvolver e comparar modelos de Machine Learning Clássico para identificar compras públicas com preço atípico e estimar o preço esperado de compras de papel para impressão, usando dados abertos do Compras.gov.br.

1.3.2 Objetivos específicos

1. Obter e organizar a base de compras pela API do Compras.gov.br, documentando a fonte e o significado de cada variável.
2. Fazer a Análise Exploratória de Dados (EDA), verificando dados faltantes, valores extremos, unidades de medida e o desbalanceamento das classes.
3. Criar uma medida de preço comparável entre compras diferentes (reais por quilo de papel) e a regra de compra atípica.
4. Preparar os dados e criar novas colunas que descrevam a compra sem usar o preço.
5. Treinar e ajustar dois modelos de classificação (Regressão Logística e Random Forest), priorizando F1 e Recall.
6. Comparar quatro modelos de regressão para estimar o preço esperado.
7. Verificar quais variáveis mais pesam na previsão.
8. Juntar as duas etapas no valor em risco e medir o ganho em relação a escolher compras ao acaso.
9. Aplicar o K-Means para identificar perfis de compra.
10. Discutir as limitações e os riscos de usar esse modelo na prática.

1.4 FUNDAMENTAÇÃO TEÓRICA

a) Conceitos-chave

Pesquisa de preços. É o levantamento que o órgão faz antes de comprar, para estimar quanto o item deve custar. No governo federal ela segue a Instrução Normativa SEGES/ME nº 65/2021, que manda usar pelo menos três preços, tirados de sistemas oficiais, contratações anteriores, sites ou fornecedores, e calcular a média, a mediana ou o menor valor (BRASIL, 2021b).

b) Estatísticas e fatos

- As compras governamentais equivalem em média a cerca de 12,5% do PIB do Brasil (RIBEIRO; INÁCIO JÚNIOR, 2019).

c)Soluções sem Machine Learning e suas limitações

A Instrução Normativa SEGES/ME nº 65, de 7 de julho de 2021 (IN 65/2021) é o normativo federal que regulamenta o procedimento administrativo para a realização de pesquisa de preços

A pesquisa de preços da IN 65/2021 é a solução oficial e funciona bem quando o servidor encontra preços parecidos. O problema é que ela não define o que é um valor "excessivamente elevado", depende do cuidado de cada servidor e usa bases que já trazem erros de unidade.

O Painel de Preços do governo federal ajuda a encontrar preços de outras compras, mas é uma ferramenta de consulta: alguém precisa ir até ela e saber o que procurar. Ela não aponta sozinha as compras fora do padrão

1.4.2 Referencial teórico em Machine Learning

Modelo A: Regressão Logística

A Regressão Logística soma as características da compra, cada uma multiplicada por um peso, e passa o resultado por uma função que aperta tudo entre 0 e 1. O número que sai é a probabilidade de a compra ser atípica. Os pesos são aprendidos com os exemplos de treino.

Na classificação, a Precision diz, entre as compras que o modelo apontou como atípicas, quantas realmente eram. O Recall diz, entre as compras atípicas de verdade, quantas o modelo pegou. O F1 junta os dois numa nota só. O ROC-AUC mede se o modelo coloca as compras na ordem certa de risco, sem depender do corte escolhido.

1.5.1 Análise Exploratória de Dados (EDA)

Descrição. A base tem 1.350 linhas e 18 colunas. São 14 colunas vindas da API de preços (identificador, código do item, data, modalidade, forma, critério de julgamento, quantidade, preço unitário, unidade de fornecimento, capacidade da embalagem, UF, esfera, UASG e CNPJ do fornecedor) e 4 do catálogo (tipo de papel, tamanho, gramatura e cor). Três colunas são numéricas (quantidade, preço e capacidade), duas são códigos inteiros e as demais são texto. As compras vêm de 646 unidades compradoras, nos 27 estados, das três esferas (593 federais, 399 estaduais e 358 municipais), e envolvem 124 itens diferentes do catálogo e 447 fornecedores.

Linhas duplicadas. Nenhuma. Cada item de compra tem um identificador único. Há linhas muito parecidas, como vários lotes do mesmo papel na mesma compra, mas são itens diferentes e foram mantidas.

O preço bruto não é comparável. O mesmo papel aparece vendido por folha (110 compras) ou por embalagem (1.240 compras), e as embalagens vão de 10 a 500 folhas. Além disso, uma folha A3 tem o dobro de papel de uma A4. Por isso convertemos tudo para reais por quilo de papel: área da folha × gramatura × folhas por unidade dá os quilos de cada unidade comprada, e o preço unitário dividido por esses quilos dá o preço por kg. Uma resma A4 de 75 g/m² pesa 2,34 kg; se custou R$ 20,00, o preço é R$ 8,55 por kg.

Valores extremos. O preço por kg tem mediana de R$ 10,90, mas vai de R$ 0,05 a R$ 447.990. Nenhum papel custa isso: esses extremos são quase sempre erros de unidade, como uma resma cadastrada como se fosse uma folha. Não removemos esses valores, porque identificá-los é justamente o objetivo do projeto. Em 94 compras o preço por kg é mais de 10 vezes a mediana do seu grupo.

Grupos de comparação. Couchê e papel texturizado são naturalmente mais caros por quilo que o sulfite. Por isso cada compra só é comparada com compras do mesmo tipo de papel. O tipo "permanente" tinha só 2 compras e foi juntado com o texturizado no grupo de papéis especiais.

Regra de compra atípica. A compra é atípica quando o preço por kg passa de Q3 + 1,5 × IQR do seu grupo, a mesma regra que marca os pontos extremos de um boxplot (TUKEY, 1977). Os quartis foram calculados só com as compras de treino. O resultado está na Tabela 1.

Divisão dos dados. Separamos 80% das compras para treino (1.080) e 20% para teste (270). O teste funciona como uma prova que o modelo nunca viu: só é usado no final, para medir se ele aprendeu de verdade ou só decorou. A divisão foi estratificada pelo tipo de papel e foi feita antes de criar o alvo, para que o próprio limite de preço atipico fosse aprendido só com o treino. Ficaram 13,5% de atipicas no treino e 12,6% no teste. Para ajustar os modelos, usamos validação cruzada em 5 partes, sempre dentro do treino: em cada rodada, 4 partes treinam o modelo e 1 parte o valida. Na prática, as 1.350 compras ficam divididas em 64% para treino (864), 16% para validação (216) e 20% para teste (270). Essa divisão em três conjuntos é importante porque a validação serve para escolher os hiperparâmetros sem tocar no teste; assim, a nota final no teste não é otimista e mostra como o modelo se comportaria com compras novas.

Dados ausentes. Não houve preenchimento. A única coluna com faltantes (critério de julgamento) foi deixada de fora do modelo, pelos motivos explicados na EDA. As colunas do catálogo foram completadas para todos os 124 itens, então não sobrou nenhum faltante nas variáveis usadas.

Sem preço na classificação. O alvo da classificação é feito a partir do preço. Se o preço entrasse como variável, o modelo estaria "prevendo" a resposta olhando a resposta. Por isso a classificação usa só o que se sabe da compra antes do preço final: o que se compra, quanto, de que forma e por quem.

Codificação das categorias. Tipo de papel, modalidade, esfera e região são rótulos, não quantidades. Usamos One-Hot, que transforma cada categoria numa coluna de sim ou não. A inexigibilidade tinha uma única compra e foi juntada com a dispensa no grupo "contratação direta".

Padronização. Usamos o StandardScaler, que coloca as colunas numéricas na mesma escala, com média 0 e desvio 1. Sem isso, as folhas por embalagem (até 500) dominariam a área da folha (menos de 1 m²). Escolhemos o StandardScaler em vez do MinMaxScaler porque há valores extremos, que fariam o MinMaxScaler espremer quase todas as compras perto do zero. A padronização fica dentro de um Pipeline, para ser calculada só com os dados de treino.

Engenharia de atributos. Criamos estas colunas:

- **preco_kg:** preço por quilo de papel, usado para criar o alvo e como alvo da regressão.
- **area_m2 e gramatura_g:** área da folha e gramatura, tiradas do texto do catálogo.
- **folhas_unid:** folhas por unidade comprada (1 quando a unidade é a folha).
- **log_quantidade e log_kg_total:** tamanho da compra em escala log, porque a quantidade vai de 1 a mais de 600 mil.
- **unidade_folha:** 1 se o item foi cadastrado por folha.
- **formato_a4, cor_branca e registro_precos:** indicadores de papel A4, papel branco e compra por ata de registro de preços.
- **regiao e mes:** região do país, a partir da UF, e mês da compra.

1.5.3 Implementação, treinamento e otimização

Os modelos foram treinados com a biblioteca scikit-learn, cada um dentro de um Pipeline junto com a padronização e o One-Hot. Nos dois modelos de classificação usamos o ajuste de peso das classes (class_weight = balanced), que faz o erro sobre as compras atípicas pesar mais. Sem isso o modelo percebe que dizer "nenhuma é atípica" já acerta 87% e para de arriscar.

Os hiperparâmetros foram ajustados com GridSearchCV, que testa várias combinações e escolhe a melhor em validação cruzada de 5 partes, só com dados de treino. Na classificação o critério foi o F1; na regressão, o menor erro médio absoluto.

Análise critica

O Random Forest foi o melhor modelo de classificação e de regressão porque o preço atípico depende de combinações entre variáveis, e ele pega isso sozinho. A vantagem sobre os modelos lineares foi clara na regressão (R^2 de 0,58 contra 0,33) e moderada na classificação (F1 de 0,58 contra 0,49). A Regressão Logistica tem a vantagem de ser explicável, o que num órgão de controle também pesa. Há, portanto, uma compensação entre desempenho e interpretabilidade: o Random Forest acerta mais (F1 de 0,583 contra 0,490), mas só informa a importância geral de cada variável, enquanto a Logistica mostra o sinal e o peso de cada uma, o que ajuda o auditor a justificar por que uma compra foi escolhida para revisão.

O resultado mais útil do projeto não era o esperado. Imaginávamos encontrar diferenças de preço por região ou por modalidade, mas o fator dominante foi a qualidade do cadastro da unidade de fornecimento. Isso muda a recomendação: antes de caçar sobrepreço, vale limpar a base.

1.5.5 Conclusão, produto final e cronograma

Resposta ao problema

A pergunta do projeto era quais compras merecem revisão por apresentarem preço fora do padrão de itens comparáveis. A resposta é uma fila de revisão ordenada por valor em risco, em que os 10% do topo concentram 97,9% do valor em risco e têm 6,5 vezes mais compras atípicas que a média. O modelo de regressão ainda entrega um preço esperado para cada compra, que pode servir de referência na pesquisa de preços.

A recomendação prática tem duas partes. Na entrada dos dados, validar a unidade de fornecimento e a capacidade da embalagem sempre que o preço por kg sair muito do padrão, o que limparia a base que todo o governo usa como referência. Na revisão, mandar para análise humana as compras do topo da fila que não forem erro de unidade, que são as candidatas a sobrepreço real. O modelo não substitui o auditor nem acusa ninguém; ele só organiza o que deve ser olhado primeiro.

BRASIL. Lei nº 14.133, de 1º de abril de 2021. Lei de Licitações e Contratos Administrativos. **Diário Oficial da União**, Brasília, DF, 1 abr. 2021a. Disponível em: https://www.planalto.gov.br/ccivil_03/_ato2019-2022/2021/lei/l14133.htm. Acesso em: 25 set. 2026.

BRASIL. Ministério da Economia. Secretaria de Gestão. Instrução Normativa SEGES/ME nº 65, de 7 de julho de 2021. Dispõe sobre o procedimento administrativo para a realização de pesquisa de preços. **Diário Oficial da União**, Brasília, DF, 2021b. Disponível em: https://www.gov.br/compras/pt-br/acesso-a-informacao/legislacao/instrucoes-normativas/instrucao-normativa-seges-me-no-65-de-7-de-julho-de-2021. Acesso em: 25 set. 2026.

BRASIL. Controladoria-Geral da União. **Alice: Analisador de Licitações, Contratos e Editais**. Brasília: CGU, 2025. Disponível em: https://www.gov.br/cgu/pt-br/assuntos/auditoria-e-fiscalizacao/alice. Acesso em: 25 set. 2026.

BREIMAN, Leo. Random Forests. **Machine Learning**, v. 45, n. 1, p. 5-32, 2001.

COMPRAS.GOV.BR. **API de Dados Abertos: módulos de Pesquisa de Preço e de Material**. Brasília, 2026a. Disponível em: https://dadosabertos.compras.gov.br/swagger-ui/index.html. Acesso em: 25 set. 2026.

COMPRAS.GOV.BR. **Compras Públicas em Dados Abertos**. Brasília, 2026b. Disponível em: https://www.gov.br/compras/pt-br/cidadao/compras-publicas-dados-abertos. Acesso em: 25 set. 2026.

MACQUEEN, James. Some methods for classification and analysis of multivariate observations. In: BERKELEY SYMPOSIUM ON MATHEMATICAL STATISTICS AND PROBABILITY, 5., 1967, Berkeley. **Proceedings**. Berkeley: University of California Press, 1967. v. 1, p. 281-297.

PEDREGOSA, Fabian et al. Scikit-learn: Machine Learning in Python. **Journal of Machine Learning Research**, v. 12, p. 2825-2830, 2011.

RIBEIRO, Cássio Garcia; INÁCIO JÚNIOR, Edmundo. **O mercado de compras governamentais brasileiro (2006-2017)**: mensuração e análise. Brasília: Ipea, 2019. (Texto para Discussão, n. 2476). Disponível em: http://repositorio.ipea.gov.br/bitstream/11058/9315/1/td_2476.pdf. Acesso em: 25 set. 2026.



